

Математическое ожидание

№35

Δ Задача боксандовского пересечения

$$\text{Функция потерь } L(y, \hat{y}) = (y - \hat{y})^2$$

Боксандовский потерь Боксандовский потерь
 Боксандовский потерь

$$D. f^*(x) = \arg \min_{\hat{f}} E((Y - \hat{f}(x))^2 | X=x), \text{ т.о.}$$

$$f^*(x) = E(Y | X=x)$$

$$E(Y - c)^2 = E(Y^2) - 2cE(Y) + c^2$$

$$(E(Y - c)^2)'_c = -2E(Y - c) = 2(c - E(Y)) = 0$$

$$\text{Вопрос: } c = E(Y) \Rightarrow f^*(x) = E(Y | X=x)$$

$$Q(f^*) = \int E((f^*(x) - Y)^2 | X) p(x) dx \geq$$

$$= \int \underbrace{E(Y)^2}_{E(Y)} - 2E(Y) + \underbrace{E(Y^2)}_{E(Y^2)} | X) p(x) dx$$

$$= \int \underbrace{E(Y^2) - E(Y)^2}_{\text{Дисперсия } Y} + E(Y | X) p(x) dx = D_Y(Y | X) E(X)$$

№36

$$L(y, \hat{y}) = [y - \hat{y}]$$

$$f(x) = \text{median}(Y | X=x)$$

где медиана минимизирует сумму абсолютных отклонений

$$R(f) = \iint |f(x) - y| p(y|x) p(x) dy dx =$$

$$= \int E(|f(x) - Y| | X) p(x) dx$$

Такое $f(x) = c$, т.о. $f^*(x) = \arg \min_c E(|c - Y| | X)$

Следовательно $c = \text{median}(Y | X=x)$

$$\Delta E(|c - Y|) = \int_{-\infty}^c |c - Y| p(y) dy = \int_{-\infty}^c (c - Y) p(y) dy - \int_c^{\infty} (c - Y) p(y) dy$$

$$\Rightarrow \int_{-\infty}^c (c - Y) p(y) dy = \int_c^{\infty} |c - Y| p(y) dy = \int_c^{\infty} (c - Y) p(y) dy + \int_a^{+\infty} |c - Y| p(y) dy$$

$$\begin{aligned}
 &= \int_{-\infty}^M (C + M - M - Y) p(y) dy = \int_{-\infty}^M C p(y) dy - 2 \int_{-\infty}^M (C - Y) p(y) dy = \\
 &= \int_{-\infty}^M (M - Y) p(y) dy + \int_{-\infty}^M (C - M) p(y) dy - \int_{-\infty}^M (C + M - M - Y) p(y) dy = \\
 &\quad \cancel{\int_{-\infty}^M (M - Y) p(y) dy} + \int_{-\infty}^M (C - M) p(y) dy - \cancel{\int_{-\infty}^M (C - M) p(y) dy} \\
 &\quad \cancel{\int_{-\infty}^M (M - Y) p(y) dy} + \int_{-\infty}^M (C - M) p(y) dy \\
 &\geq E(M - Y) + E(C - M) \quad \text{wegen } C \geq M \text{ nungrechne } 0.
 \end{aligned}$$

$$\begin{aligned}
 &= \int_{-\infty}^M (C-M) p(y) dy + \int_{-\infty}^M (M-Y) p(y) dy - 2 \int_{-\infty}^M (C-Y) p(y) dy \\
 &= \int_M^{+\infty} (C-M) p(y) dy + \int_M^{+\infty} (M-Y) p(y) dy = \\
 &= E(M-Y) - 2 \int_0^M (C-Y) p(y) dy + \int_{-\infty}^M (C-M) p(y) dy + P(C-M) M \\
 &= E(M-Y) - 2 \int_0^M (C-Y) p(y) dy \quad (C-M) \cdot \frac{1}{2} = -\frac{1}{2}(C-M) \\
 &\text{zu erhalten ist } C \\
 &+ 2 \int_0^M (Y-C) p(y) dy \geq 0 \\
 &\geq 0, \text{ falls } C = M
 \end{aligned}$$

✓37.

Наша оптимизация может, тогда $\arg \min R(f) = \text{глобальная оптимизация}$

Функция $h(y, y) = H(y, y) = \int_0^1 y' dy$

$$R(f) = \iint H(f, Y) p(y|x) dy p(x) dx = \int \underbrace{E(H(f, Y)|x)}_{\approx 0} p(x) dx$$

$$f^*(x) = \arg \min_c E(H(c, Y)|x)$$

$$E(H(c, Y)) = 0 \cdot \Pr(c=Y) + 1 \cdot \Pr(c \neq Y)$$

$$\Leftrightarrow \arg \min_c \Pr(c \neq Y) \Rightarrow c = \text{mode}(Y|x) = f^*(x)$$

максимальное значение
вероятности среди
всех возможных значений

✓38

Для класса $\{0, 1\}$ $h(y, y) = h(0, 0) = h(1, 1) = 0$

Для каждого классификатора $f^*(x)$

$$\text{усл. вероятность } f(x) = \arg \max_{y \in \{0, 1\}} \Pr(y|x)$$

$$R(f) = \int \left(\sum_{y=0}^1 L(f(x), y) \cdot \Pr(y|x) \right) p(x) dx$$

$$f^*(x) = \arg \min_c \left(h(f(x), 0) + h(f(x), 1) \Pr(y|x) \right)$$

функция, чтобы сумма вероятности минимальна \Rightarrow

если $y = 0$, то $f(x) = 0$, если $y = 1$, то $f(x) = 1$

\Rightarrow функция $h(f(x), y)$ через вероятность $\Pr(y|x)$

$$\Rightarrow f^*(x) = \arg \max_{y \in \{0, 1\}} \Pr(y|x)$$

№38

Наша $f^*(x)$ есть $h(y, y) = \ell_{yy} (y; y=1, 2..K)$

$$R(f) = \int \left[\sum_{j=1}^K h(f(x), y) \Pr(y|x) \right] p(x) dx$$

$$f^*(x) = \underset{f(x)}{\operatorname{arg\,min}} \sum_{y=1}^K h(f(x), y) \Pr(y|x) = \underset{f(x)}{\operatorname{arg\,min}} \sum_{y=1}^K \ell_{yy} \Pr(y|x)$$

То есть если в нашем $\ell_{yy} = 0 \Rightarrow$ мы имеем
минимизацию по y для каждого x

$$f^*(x) = \underset{y^*}{\operatorname{arg\,min}} \sum_{y \in Y} \ell_{yy} \Pr(y|x)$$

nt.

$$\frac{\partial g}{\partial x} = \begin{pmatrix} \frac{\partial g_1}{\partial x_1} & \frac{\partial g_1}{\partial x_2} & \cdots & \frac{\partial g_1}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial g_m}{\partial x_1} & \frac{\partial g_m}{\partial x_2} & \cdots & \frac{\partial g_m}{\partial x_n} \end{pmatrix} \quad g = \begin{pmatrix} g_1 \\ \vdots \\ g_m \end{pmatrix}$$

1. D! $\alpha \in \mathbb{R}^n$ $x \in \mathbb{R}^n$, so $\frac{\partial(\alpha^T x)}{\partial x} = \alpha$

$$\alpha^T x = \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_n x_n$$

$$\frac{\partial \alpha^T x}{\partial x} = \frac{\partial}{\partial x} (\alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_n x_n) = \begin{pmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{pmatrix} = \alpha$$

2. $A = \begin{pmatrix} a_{11} & \dots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \dots & a_{mn} \end{pmatrix} \quad x \in \mathbb{R}^n \quad \frac{\partial Ax}{\partial x} = A$

$AX = (a_{ij})(x_j) = \begin{pmatrix} a_{11} x_1 + a_{12} x_2 + \dots + a_{1n} x_n \\ \vdots \\ a_{m1} x_1 + \dots + a_{mn} x_n \end{pmatrix}$

$$\frac{\partial Ax}{\partial x} = \begin{pmatrix} a_{11} & \dots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \dots & a_{mn} \end{pmatrix}$$

3. ~~$Ax = (a_{11} \dots a_{1n}) x = (x_1 \dots x_n) \frac{\partial(A^T Ax)}{\partial x} = (A + A^T)x$~~

~~$$Ax = x_1 a_{11} + \dots + x_n a_{1n}$$~~
~~$$x_1 a_{21} + \dots + x_n a_{2n}$$~~
~~$$(x_1 a_{11} + \dots + x_n a_{1n}, x_1 a_{21} + \dots + x_n a_{2n}, \dots, x_1 a_{m1} + \dots + x_n a_{mn})$$~~
~~$$\frac{\partial(Ax)}{\partial x} = \begin{pmatrix} a_{11} & \dots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \dots & a_{mn} \end{pmatrix} x = x_1 a_{11} + \dots + x_n a_{1n}$$~~
~~$$x_1 a_{21} + \dots + x_n a_{2n}$$~~
~~$$x_1 a_{m1} + \dots + x_n a_{mn}$$~~

~~$$Ax = \sum_{j=1}^n a_{1j} x_j$$~~

~~$$(x_1, x_2, \dots, x_n) \left(\sum_{j=1}^n a_{1j} x_j \right)$$~~

~~$$= x_1 \cdot \sum_{j=1}^n a_{1j} x_j$$~~

~~$$x^T Ax = \sum_{i=1}^n x_i \cdot \sum_{j=1}^n a_{ij} x_j$$~~

~~$$\frac{\partial(Ax)}{\partial x} =$$~~

~~$$= x_i \cdot \sum_{j=1}^n a_{ij} x_j$$~~

$$3) A = \begin{pmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{n1} & \dots & a_{nn} \end{pmatrix} \quad x^T = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \quad A^T = \begin{pmatrix} a_{11} & a_{21} & \dots & a_{n1} \\ \vdots & \vdots & & \vdots \\ a_{n1} & \dots & a_{nn} \end{pmatrix}$$

$$\begin{aligned} x^T A x &= (x_1, x_2, \dots, x_n) \cdot \begin{pmatrix} a_{11} x_1 + \dots + a_{1n} x_n \\ \vdots \\ a_{n1} x_1 + \dots + a_{nn} x_n \end{pmatrix} \\ &= x_1 \cdot \sum_{j=1}^n a_{1j} x_j + \dots + x_n \cdot \sum_{j=1}^n a_{nj} x_j \\ &= \sum_{i=1}^n x_i \sum_{j=1}^n a_{ij} x_j \end{aligned}$$

$$\begin{aligned} \frac{\partial (x^T A x)}{\partial x} &= \begin{pmatrix} 2a_{11}x_1 + \dots + a_{1n}x_n + a_{21}x_2 + a_{31}x_3 + \dots + a_{n1}x_n \\ \vdots \\ a_{1n}x_1 + x_2a_{2n} + \dots + 2a_{nn}x_n \end{pmatrix} \\ \frac{\partial g}{\partial x} &= \begin{pmatrix} \frac{\partial g}{\partial x_1} \\ \vdots \\ \frac{\partial g}{\partial x_n} \end{pmatrix} = (A + A^T)x \end{aligned}$$

$$4) x \in \mathbb{R}^n, \text{ so } \frac{\partial \|x\|^2}{\partial x} = 2x \quad \frac{\partial \sum_{i=1}^n x_i^2}{\partial x} = \begin{pmatrix} 2x_1 \\ 2x_2 \\ \vdots \\ 2x_n \end{pmatrix} = 2x$$

$$5) \frac{\partial g(x)}{\partial x} = \begin{pmatrix} g'_1 & 0 & \dots & 0 \\ 0 & g'_2 & & \\ \vdots & & \ddots & \\ 0 & \dots & 0 & g'_{n-1} \end{pmatrix}$$

$$\begin{aligned} g(x) &= \begin{pmatrix} g(x_1) \\ \vdots \\ g(x_n) \end{pmatrix} \\ \frac{\partial g}{\partial x} &= \begin{pmatrix} \frac{\partial g}{\partial x_1}(x_1) & \frac{\partial g}{\partial x_2}(x_1) & \dots & \frac{\partial g}{\partial x_n}(x_1) \\ \frac{\partial g}{\partial x_1}(x_2) & \frac{\partial g}{\partial x_2}(x_2) & \dots & \frac{\partial g}{\partial x_n}(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial g}{\partial x_1}(x_n) & \frac{\partial g}{\partial x_2}(x_n) & \dots & \frac{\partial g}{\partial x_n}(x_n) \end{pmatrix} \end{aligned}$$

$$6) h: \mathbb{R}^n \rightarrow \mathbb{R}^m \\ g: \mathbb{R}^m \rightarrow \mathbb{R} \\ x \in \mathbb{R}^n$$

$$\frac{\partial g(h(x))}{\partial x} = \frac{\partial g(h(x))}{\partial h(x)} \cdot \frac{\partial h(x)}{\partial x}$$

$$\begin{aligned} h(x) &= \cancel{h(x_1)} \\ g(h(x)) &= \cancel{g(h(x_1))} \\ \frac{\partial g(h(x))}{\partial x} &\cancel{=} \cancel{g(h(x_1))} \end{aligned}$$

$$\frac{\partial g(h(x))}{\partial x} = \left(\sum_{i=1}^m \frac{\partial g_i}{\partial h_i} \frac{\partial h_i}{\partial x_1} \dots \sum_{i=1}^m \frac{\partial g_i}{\partial h_i} \frac{\partial h_i}{\partial x_n} \right) = \frac{\partial g(h(x))}{\partial h} \frac{\partial h(x)}{\partial x}$$

N16

x_1	4	0	-2	2	График
x_2	3	1	-3	-1	Диаграма

$$X = \begin{pmatrix} 4 & 3 \\ 0 & 1 \\ -2 & -3 \\ 2 & -1 \end{pmatrix} \quad 1. \text{ Центральный элемент}$$

$$\bar{x} = \frac{1}{N} (\sum x_{1i}, \sum x_{2i}) = \frac{1}{4} (4, 0)$$

$$\bar{X} = (1, 0)$$

$$X_c = X - \bar{X} = \begin{pmatrix} 3 & 3 \\ -1 & 1 \\ -3 & -3 \\ 1 & -1 \end{pmatrix}$$

2. Ковариансы

$$C = X_c^T X_c = \begin{pmatrix} 20 & 16 \\ 16 & 20 \end{pmatrix}$$

Модифицированные ковариансы $\frac{1}{N-1} C = \frac{1}{3} \begin{pmatrix} 20 & 16 \\ 16 & 20 \end{pmatrix}$

3. Найдем собственные числа и единичные векторы C

$$\Delta = \begin{vmatrix} 20-\lambda & 16 \\ 16 & 20-\lambda \end{vmatrix} = 0 \quad \Delta = \lambda^2 - 40\lambda + 144 = 0$$

$$\lambda_1 = 36 \quad \lambda_2 = 4$$

$$36 = \lambda_1: \begin{pmatrix} -16 & 16 \\ 16 & -16 \end{pmatrix} \begin{pmatrix} \tilde{v}_1 \\ \tilde{v}_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \tilde{v}_1 \cdot \tilde{v}_2 = 1 \quad \tilde{v}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$


$$4 = \lambda_2: \begin{pmatrix} 16 & 16 \\ 16 & 16 \end{pmatrix} \begin{pmatrix} \tilde{v}_1 \\ \tilde{v}_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \tilde{v}_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$$


Нормировка: $\sqrt{c^2 + c^2} = 1 \quad \sqrt{2}c = 1 \quad c = \frac{\sqrt{2}}{2}$

$$\tilde{v}_1 = \frac{\sqrt{2}}{2} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \quad \tilde{v}_2 = \frac{\sqrt{2}}{2} \begin{pmatrix} -1 \\ 1 \end{pmatrix}$$

\tilde{v}_1, \tilde{v}_2 - единичные ортогональные

$$\frac{1}{N-1} \lambda_1 = \frac{1}{N-1} \tilde{b}_1^2 = \frac{36}{3} = 12 \quad \frac{1}{N-1} \lambda_2 = \frac{1}{N-1} \tilde{b}_2^2 = \frac{4}{3}$$

x_2  единичные ортогональные компоненты



№ 48

Влияние шума на измерение предела текучести

Пр-во признаков - одномерное

Обычные выборки $X^{(0)} = 0 \quad X^{(1)} = 1$

Добавлены случайные признаки $X^{(0)} = (0, \varepsilon_1) \quad X^{(1)} = (1, \varepsilon_2)$

Найдем вероятность, что $X \in (0.32, 0)$ сравнив $X^{(1)}$


$$P(X^{(1)}, X) = 0.32^2 + \varepsilon_1^2$$

$$P(X^{(1)}, X) = (1 - 0.32)^2 + \varepsilon_2^2 = 0.68^2 + \varepsilon_2^2$$

$$\text{Найдем } P(0.68^2 + \varepsilon_2^2 \leq 0.32^2 + \varepsilon_1^2)$$

$$P(0.36 + \varepsilon_2^2 \leq \varepsilon_1^2) = \iiint_{\varepsilon_1, \varepsilon_2} f_{\varepsilon_1, \varepsilon_2}(x_1, x_2) dx_1 dx_2$$

$$D: 0.36 + \varepsilon_2^2 \leq \varepsilon_1^2$$



$$\begin{aligned} &= \iint_{\varepsilon_1, \varepsilon_2} \frac{1}{2\pi} e^{-\frac{\varepsilon_1^2}{2}} e^{-\frac{\varepsilon_2^2}{2}} \delta(\varepsilon_1 - \sqrt{0.36 + \varepsilon_2^2}) d\varepsilon_1 d\varepsilon_2 \\ &= \int_0^{0.8} \int_0^{\sqrt{0.36 + \varepsilon_2^2}} \frac{1}{2\pi} e^{-\frac{\varepsilon_1^2}{2}} e^{-\frac{\varepsilon_2^2}{2}} d\varepsilon_1 d\varepsilon_2 \\ &\approx 0.20225 \end{aligned}$$

№4.1

так можно

Доказать, что $\bar{v}_0 = \bar{x}$

Наша же это задача наих минимум сущестует
последний это максимум минимума

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x^{(i)}$$

Минимум. $w_k = v_0 + h(v_1, \dots, v_K) \quad v_j \in \mathbb{R}^d \quad \|v_j\| \geq 1 \quad v_j \perp v_i \quad (j \neq i)$

$$\text{т.к. } \sum_{i=1}^N \text{dist}^2(x^{(i)}, w_k) = \sum_{i=1}^N \|\text{орт}_{w_k} x^{(i)}\|^2 =$$

$$= \sum_{i=1}^N \|x^{(i)} - v_0 - \sum_{j=1}^K (x^{(i)} - v_0, v_j) v_j\|^2 \rightarrow \min$$

v_j - единичный вектор компоненты которого ненулевые

$$\underset{v_0}{\arg \min} \sum_{i=1}^N \|x^{(i)} - v_0\|^2$$

$$\underbrace{\partial \left(\sum_{i=1}^N \|x^{(i)} - v_0\|^2 \right)}_{\partial v_0} = \sum_{i=1}^N 2(x^{(i)} - v_0) = 0$$

$$\sum_{i=1}^N (x^{(i)} - v_0) = 0$$

$$\sum_{i=1}^N x^{(i)} - N v_0 = 0$$

$$v_0 = \frac{1}{N} \sum_{i=1}^N x^{(i)} = \bar{x}$$

т.д.

№4.2

$$\textcircled{1} \quad X V_k = U_k \Sigma_k$$

известно $X = U \Sigma V^T$

Но иначе



$$X V_k = U \Sigma V^T V_k = ? U_k \Sigma_k$$

$$U \cdot \Sigma \cdot \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} = U \cdot \begin{pmatrix} \Sigma_k & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} = U \cdot \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \Sigma_k = U_k \Sigma_k$$

✓ 3.

Определение коэффициентов:

$$\begin{array}{c} x \\ y \end{array} \begin{array}{cccc} 1 & 0 & 0 & -1 \\ 4 & 0 & 2 & 6 \end{array}$$



2) МНК

$$f(x) = \beta_0 + \beta_1 x + \beta_2 x^2$$

$$X = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & -1 & 1 \end{bmatrix} \quad f = \begin{pmatrix} 4 \\ * \\ 0 \\ 6 \end{pmatrix}$$

$$X^T X = \begin{bmatrix} 4 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix}$$

$$X^T y = \begin{bmatrix} 12 \\ -2 \\ 10 \end{bmatrix}$$

Решение системы

$$X^T X \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix} = \begin{bmatrix} 12 \\ -2 \\ 10 \end{bmatrix} = X^T y$$

$$\begin{bmatrix} 4 & 0 & 2 \\ 0 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix} = \begin{bmatrix} 12 \\ -2 \\ 10 \end{bmatrix} \quad \beta = \begin{pmatrix} 1 \\ -1 \\ 4 \end{pmatrix}$$

$$f(x) = 1 - x + 4x^2$$

3) Решение методом наименьших квадратов

$$\text{Решение методом наименьших квадратов: } (X^T X + \lambda I) \beta = X^T y$$

$$\begin{bmatrix} 4+\lambda & 0 & 2 \\ 0 & 2+\lambda & 0 \\ 2 & 0 & 2+\lambda \end{bmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix} = \begin{pmatrix} 12 \\ -2 \\ 10 \end{pmatrix}$$

$$\begin{bmatrix} 5 & 0 & 2 \\ 0 & 3 & 0 \\ 2 & 0 & 3 \end{bmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix} = \begin{bmatrix} 12 \\ -2 \\ 10 \end{bmatrix} \quad \beta \approx \begin{pmatrix} 1.45 \\ -0.7 \\ 2.36 \end{pmatrix}$$

$$f(x) = 1.45 - 0.7x + 2.36x^2$$

№4.

а) Задача восстановления регрессии
y предсказан по нормальной ячейке:

$$N(X\beta, \sigma^2 I)$$

если β имеет априорное распределение $N(0, \Sigma^{-1})$

тогда апостериорное распределение для β

$$\text{такое } P_{\beta|Y,X}(y|x|\beta) = \frac{1}{(\sqrt{2\pi}\sigma)^n} \cdot e^{-\frac{1}{2\sigma^2} (y - X\beta)^T (y - X\beta)}$$

$$P_{\beta}(\beta) = \frac{1}{(\sqrt{2\pi}\Sigma)^d} e^{-\frac{1}{2\Sigma} \beta^T \beta}$$

$$P_{\beta|Y,X}(\beta|y,x) = \frac{P_{Y,X|\beta}(y,x|\beta) \cdot P_{\beta}(\beta)}{P_{Y,X}(y,x)} = \frac{1}{(\sqrt{2\pi})^{n+d}} \frac{e^{-\frac{1}{2} \frac{\|y-X\beta\|^2 + \|\beta\|^2}{\sigma^2}}}{\sigma^{n+d} \sqrt{\det(\Sigma)}}$$

$$\propto \frac{\|y-X\beta\|^2 + \|\beta\|^2}{\sigma^2} = \frac{1}{\sigma^2} (y - X\beta)^T (y - X\beta) + \frac{1}{\sigma^2} \beta^T \beta$$

$$\text{2) } \frac{1}{\sigma^2} (y^T y - 2\beta^T X^T y + \beta^T \beta) + \frac{\beta^T \beta}{\sigma^2} = \frac{1}{\sigma^2} yy^T - \frac{2}{\sigma^2} \beta^T X^T y$$

$$+ \underbrace{\omega^T (\frac{1}{2\sigma^2} A^T A + \frac{1}{\sigma^2} I)}_{\text{матрица}} \omega = \frac{1}{\sigma^2} yy^T - \frac{2}{\sigma^2} \beta^T X^T y + \omega^T \Sigma \omega$$

$$\frac{1}{\sigma^2} \beta^T X^T y = \beta^T \underbrace{\sum_{j=1}^n x_j^T y}_{\text{матрица}} \rightarrow y = \frac{1}{\sigma^2} \sum_{j=1}^n x_j^T y$$

$$\text{Тогда } (\omega - \frac{1}{\sigma^2} \sum_{j=1}^n x_j^T y)^T \Sigma (\omega - \frac{1}{\sigma^2} \sum_{j=1}^n x_j^T y) \sim N(\underbrace{0}_{\text{матрица}}, \Sigma^{-1})$$

$$P(y|x|\beta) = \text{const} \cdot e^{-\frac{1}{2\sigma^2} \|y - X\beta\|^2}$$

Параметр регрессии $\beta = \frac{5}{2}$

$$\Delta P_{(y,x|\beta)} - \text{априор.распределение} \Rightarrow \text{Model}(\beta) = \beta^{\text{ridge}} = F(\beta)$$

15

X_1	0	0	1	0	0	1	1	1	0
X_2	0	1	0	1	1	1	1	1	1
Y	0	0	0	0	0	1	1	1	1

$$\text{Determine } \Pr(Y=0 | X_1=1, X_2=1)$$

$$\Pr(Y=1 | X_1=1, X_2=1)$$

$$\Pr(Y=0 | X_1=1, X_2=1) \approx \frac{\Pr(X_1=1 | Y=0) \Pr(X_2=1 | Y=0) \Pr(Y=0)}{\Pr(X_1=1 | X_2=1)}$$

Gegeben: Beobachtungen:

$$\Pr(X_1=1 | Y=0) = \frac{1}{5}$$

$$\Pr(X_2=1 | Y=0) = \frac{3}{5}$$

$$\Pr(Y=0) = \frac{1}{2}$$

$$\Pr(X_1=1 | X_2=1) = \Pr(Y=0) \cdot \Pr(X_1=1 | Y=0) + \Pr(Y=1) \Pr(X_1=1 | Y=1)$$

$$\Pr(X_1=1, X_2=1) = \frac{1}{2} \cdot \frac{1}{5} \cdot \frac{3}{5} + \Pr(X_2=1 | Y=1)$$

$$\frac{1}{2} \cdot \frac{3}{5} \cdot 1 = \frac{3}{10}$$

$$\Pr(Y=0 | X_1=1, X_2=1) = \frac{\frac{1}{2} \cdot \frac{3}{5} \cdot \frac{1}{2}}{\frac{6+15}{50}} = \frac{2}{7}$$

$$\Pr(Y=1 | X_1=1, X_2=1) = \frac{\Pr(X_1=1 | Y=1) \Pr(X_2=1 | Y=1) \Pr(Y=1)}{\Pr(X_1=1, X_2=1)}$$

$$= \frac{\frac{3}{5} \cdot 1 \cdot \frac{1}{2}}{\frac{21}{50}} = \frac{5}{21}$$

N 8

$$\begin{matrix} x_1 & 0 & 1 & 0 & 2 & 2 & 2 & 4 & 3 \\ x_2 & -1 & 0 & 0 & 0 & 1 & 0 & 1 & 2 \end{matrix}$$

$$y \underbrace{\begin{matrix} 0 & 0 & 0 & 0 & 0 & 1 & 1 & 1 \end{matrix}}_{\text{одноравномерное}}$$

Несимметрическое распределение

Оценки вероятности классов: $\Pr(Y=0) = \frac{5}{8}$ $\Pr(Y \geq 1) = \frac{3}{8}$

Оценка средние для классов при $Y \geq 0$: $\hat{y}_{\geq 0} = \begin{pmatrix} 0+1+0+2+2 \\ 5 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$

$$Y_{\geq 1} \quad \hat{y}_1 = \begin{pmatrix} \frac{2+4+3}{3} \\ 0+1+2 \\ 3 \end{pmatrix} = \begin{pmatrix} 3 \\ 1 \end{pmatrix}$$

Бибортное выражение ковариации для каждого класса

$$\hat{\Sigma}_0 = \frac{1}{N_0-1} \sum_{y^{(i)}=0} (x^{(i)} - \hat{y}_{\geq 0})(x^{(i)} - \hat{y}_{\geq 0})^T = \frac{1}{4} \left(\begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \right)$$

$$\textcircled{2} \quad \frac{1}{4} \begin{pmatrix} 4 & 2 \\ 2 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 0.5 \end{pmatrix}$$

$$\hat{\Sigma}_1 = \frac{1}{N_1-1} \sum_{y^{(i)}=1} (x^{(i)} - \hat{y}_1)(x^{(i)} - \hat{y}_1)^T = \frac{1}{2} \cdot \left(\begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \right) \textcircled{2}$$

$$\textcircled{2} \quad \frac{1}{2} \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix}$$

Оценка матрицы ковариации

$$\hat{\Sigma} = \frac{1}{N-K} \sum_{k=1}^K \sum_{y^{(i)}=k} (x^{(i)} - \hat{y}_k)(x^{(i)} - \hat{y}_k)^T = \frac{1}{6} \left(\begin{pmatrix} 4 & 2 \\ 2 & 2 \end{pmatrix} + \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \right) \textcircled{2}$$

$$\textcircled{2} \quad \frac{1}{6} \begin{pmatrix} 6 & 3 \\ 3 & 4 \end{pmatrix} = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 2 \end{pmatrix}$$

$$\hat{\Sigma}_0^{-1} = \begin{pmatrix} 2 & -2 \\ -2 & 4 \end{pmatrix} \quad \hat{\Sigma}_1^{-1} = \begin{pmatrix} \frac{4}{3} & -\frac{2}{3} \\ -\frac{2}{3} & \frac{1}{3} \end{pmatrix} \quad \hat{\Sigma}^{-1} = \begin{pmatrix} \frac{8}{5} & -\frac{6}{5} \\ -\frac{6}{5} & \frac{12}{5} \end{pmatrix}$$

Аналитичне гиперплоскостное оптимизение

$$\begin{aligned}\bullet \quad \hat{\delta}_0(x) &= x^T \hat{\Sigma}^{-1} \hat{j}_{10} - \frac{1}{2} \hat{j}_{10}^T \hat{\Sigma}^{-1} \hat{j}_{10} + \ln \hat{P}_r(Y=0) = \\ &= \begin{pmatrix} x_1 & x_2 \end{pmatrix} \cdot \begin{pmatrix} \frac{8}{5} & -\frac{6}{5} \\ -\frac{6}{5} & \frac{12}{5} \end{pmatrix} \cdot \begin{pmatrix} 1 \\ 0 \end{pmatrix} - \frac{1}{2} \begin{pmatrix} 10 \end{pmatrix} \begin{pmatrix} \frac{8}{5} & -\frac{6}{5} \\ -\frac{6}{5} & \frac{12}{5} \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \\ &+ \ln \left(\frac{3}{8} \right) = 1.6x_1 - 1.2x_2 - 0.8 - 0.47 = \\ &= 1.6x_1 - 1.2x_2 - 1.27\end{aligned}$$

$$\bullet \quad \hat{\delta}_1(x) = -11 - 3.6x_1 - 1.2x_2 - 5.78$$

Пригенироване поверхности: $\hat{\delta}_0(x) = \hat{\delta}_1(x)$

$$2x_1 + 0.6x_2 - 2.255 = 0$$


$$x_1 = 2.255 - 0.6x_2$$

Квадратичне гиперплоскостное оптимизение

$$\begin{aligned}\bullet \quad \hat{\delta}_0(x) &= -\frac{1}{2} \ln \Delta \hat{\Sigma}_0 - \frac{1}{2} (x - \hat{j}_{10})^T \hat{\Sigma}_0^{-1} (x - \hat{j}_{10}) + \ln \hat{P}_r(Y=0) \\ &= -x_1^2 + 2x_1x_2 + 2x_1 - 2x_2 - 2x_2^2 - 0.78\end{aligned}$$

$$\begin{aligned}\bullet \quad \hat{\delta}_1(x) &= -11 - 0.67x_1^2 - 0.67x_2^2 + 0.67x_1x_2 + 3.33x_1 \\ &\quad - 0.67x_2 - 0.55\end{aligned}$$

$$\begin{aligned}\bullet \quad \text{Пригенироване} \quad \hat{\delta}_0 &= \hat{\delta}_1 : 0.33x_1^2 - 1.33x_1x_2 + 1.33x_1 + 1.33x_2 + 1.33x_2^2 \\ &\quad - 4.72 = 0 \\ x_1^2 - 4x_1x_2 + 4x_1 + 4x_2 + 4x_2^2 - 14 &= 0\end{aligned}$$



№ 19.

Коэффициент на k -квартиль
Его выражение $\hat{g}_k(s_1, s_2, \dots, s_k) = \frac{e^{s_k}}{\sum_{l=1}^k e^{s_l}}$

Минимизация:

$$R^{(i)} = -\sum_{k=1}^K I(y^{(i)}=k) \ln g_k(\dots)$$

$$\text{CD! } 1) \frac{\partial R^{(i)}}{\partial s_l} = \hat{g}_k + \cancel{\sum_{k=1}^K I(y^{(i)}=k) \ln g_k(\dots)}$$

$$\begin{aligned} \frac{\partial R^{(i)}}{\partial s_l} &= \frac{e^{s_k}}{\sum_{l=1}^k e^{s_l}} = \frac{e^{s_k}}{(e^{s_1} + e^{s_2} + \dots + e^{s_k})} \\ &= e^{s_k} \cdot \frac{\sum_{i=1}^k s_i}{(\sum_{i=1}^k e^{s_i})^2} = e^{s_k} \cdot \frac{s_k}{(\sum_{i=1}^k e^{s_i})^2} = \hat{g}_k = \hat{g}_k \quad \square \end{aligned}$$

$$\begin{aligned} 2) \frac{\partial R^{(i)}}{\partial s_{k+l}} &= \frac{e^{s_k}}{\left(\frac{e^{s_k}}{(e^{s_1} + e^{s_2} + \dots + e^{s_k})} + e^{s_{k+l}}\right) s_{k+l}} = \frac{e^{s_k} \cdot e^{s_{k+l}}}{(\sum_{i=1}^k e^{s_i})^2} \\ &= -\hat{g}_k \cdot \hat{g}_{k+l} = \hat{g}_k (0 - \hat{g}_{k+l}) \quad \text{результат} \end{aligned}$$

$$2) \frac{\partial R^{(i)}}{\partial s_l} = -I(y^{(i)}=k) \hat{g}_k$$

$$\frac{\partial R^{(i)}}{\partial s_k} = \left(-\sum_{k=1}^K I(y^{(i)}=k) \ln g_k(s_1, s_2) \right) \hat{g}_k = -I(y^{(i)}=k) \hat{g}_k$$

$$3) \frac{\partial R^{(i)}}{\partial s_l} = g_e - I(y^{(i)}=l)$$

$$\begin{aligned} \frac{\partial R^{(i)}}{\partial s_l} &= \left(-\sum_{k=1}^K I(y^{(i)}=k) \ln f_k(s_1, \dots, s_e, s_u) \right)_{s_e}^l = \\ &= - \left[I(y^{(i)}=1) \cdot \frac{\frac{\partial g_e}{\partial s_e}}{g_e} + \dots + I(y^{(i)}=K) \cdot \frac{\frac{\partial g_K}{\partial s_e}}{g_K} \right] \quad (2) \end{aligned}$$

$$\begin{aligned} \frac{\partial g_e}{\partial s_e} &= \begin{cases} -g_e g_e & k \neq l \\ (g_e(1-g_e))^{-1} & k = l \end{cases} \quad (2) \\ &\quad \left[I(y^{(i)}=1) \cdot \left(-\frac{g_e g_e}{g_1} \right) + \dots + I(y^{(i)}=l) \cdot \left(\frac{g_e g_e}{g_l} \right) \right] \\ (2) \quad g_e \left(\sum_{k=1}^K I(y^{(i)}=k) \right) + I(y^{(i)}=l) &= \\ &= g_e - I(y^{(i)}=l) \end{aligned}$$

120

K-zagor 2-muasor nayruayor gur GLO, i3 k=1..K

oynamayor bishapqa ($x^{(i)}, y^{(i)}$)

$$y^{(i)} = (y_1^{(i)}, y_2^{(i)}, \dots, y_K^{(i)}) \in \{0,1\}^K \quad i=1,2, \dots$$

$$f_k(s_u) = \frac{1}{1+e^{-s_u}} \quad k=1,2, \dots, K$$

$$\text{Layap: } R^{(i)} = -\sum_{u=1}^K y_u^{(i)} \ln g_e + (1-y_u^{(i)}) \ln(1-g_e)$$

$$\text{D! } \frac{\partial R^{(i)}}{\partial s_l} = g_e - y_e^{(i)}$$

$$\begin{aligned} \frac{\partial R^{(i)}}{\partial s_l} &= \left(-g_e \ln g_e + (1-g_e) \ln(1-g_e) - \dots \right)_{s_e}^l = \\ &= -y_e^{(i)} \cdot \frac{g_e}{1-g_e} + (1-y_e^{(i)}) \cdot \frac{(1-g_e)}{1-g_e} \end{aligned}$$

$$g_e = \frac{e^{s_e}}{1+e^{-s_e}}$$

$$1-g_e = \frac{1+e^{-s_e}}{1+e^{-s_e}} = \frac{1}{1+e^{-s_e}}$$

$$\begin{aligned}
 \frac{\partial R^{(i)}}{\partial z_i} &= +y^{(i)} \cdot \frac{e^{-z_i}}{1+e^{-z_i}} + (1-y^{(i)}) \cdot \frac{1}{1+e^{-z_i}} \cdot e^{-z_i} \cdot g_i \\
 &= -y^{(i)}(1-g_i) + (1-y^{(i)})g_i \\
 &= -y^{(i)} + y^{(i)}g_i + g_i - y^{(i)}g_i = g_i - y^{(i)} \text{ ring}
 \end{aligned}$$

✓ 21.

2 наиважніші варіанти

$$\text{Задача змінного softmax } B(\sigma(Ax)) = g$$

Функція втрат logloss = R(g)

Потрібно зробити $x^{(i)}$: $\log_{\text{base }} \sigma(B(\sigma(Ax^{(i)})))$

Модернізація залежності з backpropagation:

Мета: зробити зваження $y = Ax$

значення функції $z = \sigma(y)$

Використовуємо 2 каскади: $t = Bz$

Приклад змінного softmax: $g = \text{softmax}(t)$

Логарифмічна функція змінного softmax:

Етап $\delta_x = \frac{\partial R^{(i)}}{\partial x}$ \times -зглибок з цим

$$\frac{\partial R^{(i)}}{\partial x} = \frac{\partial R^{(i)}}{\partial g} \cdot \frac{\partial g}{\partial t} \cdot \frac{\partial t}{\partial z} \cdot \frac{\partial z}{\partial x} = \frac{\partial R^{(i)}}{\partial g} \cdot \frac{\partial g}{\partial t} \cdot \frac{\partial (\sigma(z))}{\partial z} \cdot \frac{\partial z}{\partial x}$$

$$= (g - y) \cdot B \cdot \text{diag}(\sigma(y)) \cdot A$$

Обчислення блоків:

$$\tilde{A} = A - L \frac{\partial R^{(i)}}{\partial A}$$

ще один блок:

$$\tilde{B} = B - L \frac{\partial R^{(i)}}{\partial B}$$

$$\frac{\partial R^{(i)}}{\partial A} = \frac{\partial R^{(i)}}{\partial g} \cdot \frac{\partial g}{\partial t} \cdot \frac{\partial t}{\partial z} \cdot \frac{\partial z}{\partial A} = \sum_g x$$

$$\frac{\partial R^{(i)}}{\partial B} = \frac{\partial R^{(i)}}{\partial g} \cdot \frac{\partial g}{\partial t} \cdot \frac{\partial t}{\partial z} \cdot \frac{\partial z}{\partial B} = \sum_t z$$